

SISTEMAS DE RECOMENDACIÓN MUSICAL

Análisis de Datos, Modelos y Conclusiones

🎵 1. Preprocesamiento de Datos (EDA)

El proyecto parte de un historial de escuchas crudo uniendo el **Million Song Dataset**, **Spotify** y **Last.fm**. El "playcount" original (feedback implícito) se transformó en un **rating continuo de 1 a 5** mediante una función logarítmica y escalado min-max para poder calcular el error MSE.

533.689

USUARIOS ÚNICOS

~25.000

CANCIONES (K-CORE)

8.65M

INTERACCIONES

🤖 2. Comparativa de Modelos



K-Nearest Neighbours

- **Perfil:** Actúa como un *Motor de Descubrimiento*.
- **Métricas:** Baja Precisión (8%), pero alto Recall (45%) y excelente NDCG (44%).
- **Sesgo de centralidad:** Tiende a suavizar las predicciones hacia la media; le cuesta predecir los "1s" o "5s" puros si los vecinos no son unánimes.



Neural Collaborative Filtering

- **Arquitectura:** Multi-Layer Perceptron (MLP) que concatena embeddings de usuarios e ítems pasándolos por capas densas no lineales (ReLU).
- **Ventaja:** Captura interacciones complejas que el modelo matricial simple (GMF) no puede.
- **Enfoque:** Prioriza la calidad del ranking sobre el error de regresión.



Probabilistic Matrix Fac.

- **Método:** Basa su predicción en el producto escalar puro de los factores latentes.
- **Evaluación:** Evaluado de forma estricta con *Negative Sampling* asegurando cero exposición en entrenamiento.
- **Implementación:** Creado en PyTorch optimizando por lotes.



Bernoulli Matrix Fac.

- **Teoría:** 5 sub-modelos logísticos que calculan la probabilidad exacta de dar una nota (1 a 5).
- **Resultado:** Teóricamente sólido pero *no superó al baseline* en este caso.
- **Diagnóstico:** Brilla en ratings explícitos discretos, pero sufre con feedback implícito transformado a un continuo sintético.



3. Conclusiones del Estudio

1. **La naturaleza del dato dicta el modelo:** Transformar un "playcount" en ratings continuos (1-5) hace que modelos muy avanzados como BeMF no rindan bien al romperse sus supuestos estadísticos.
2. **Descubrimiento vs Precisión Exacta:** Un sistema puede ser malo prediciendo la nota exacta que le darás a una canción (MAE estancado), pero excelente (alto NDCG) mostrándote arriba en la lista música nueva que te va a encantar.
3. **Matrices dispersas:** Todo el proyecto optimiza la memoria utilizando matrices ``csr_matrix`` y splits estratificados 80/20 garantizando presencia en train y test.

"La complejidad teórica de un modelo no garantiza mejoras si sus fundamentos matemáticos no encajan perfectamente con la naturaleza de los datos."